

Matematički fakultet, Univerzitet u Beogradu

Predmet: Istraživanje podataka 2

Klasterovanje podataka nad IMDB skupom podataka

Seminarski rad

Student: Marko Veljović

Indeks: 17/2022

Profesor: dr Mirjana Maljković Ružičić

April 2026.

Sadržaj

1	Uvod	3
2	Opis skupa podataka	3
2.1	Poreklo i osnovne karakteristike	4
2.2	Struktura atributa	4
2.3	Ciljna promenljiva i njena uloga u evaluaciji	4
3	Preprocesiranje podataka	5
3.1	Učitavanje i početna obrada	5
3.2	Provera i uklanjanje praznih atributa	5
3.3	Skaliranje podataka	5
3.4	Stratifikovano uzorkovanje	6
3.5	Redukcija dimenzionalnosti primenom SVD metode	6
4	Metodologija	7
4.1	Pristup klasterovanju	7
4.2	Reprezentacije podataka	7
4.3	Izabrani algoritmi klasterovanja	8
4.3.1	MiniBatchKMeans	8
4.3.2	Agglomerative Clustering	8
4.3.3	Gaussian Mixture Model (GMM)	8
4.3.4	Birch	9
4.3.5	DBSCAN	9
5	Eksperimentalno podešavanje	9
5.1	Korišćene reprezentacije	10
5.2	Parametri algoritama	10
5.3	Organizacija eksperimenata	10
5.4	Čuvanje rezultata i reproduktivnost	11

6	Metrike evaluacije	12
6.1	Interne metrike	12
6.1.1	Silhouette koeficijent	13
6.1.2	Davies–Bouldin indeks	13
6.1.3	Calinski–Harabasz indeks	13
6.2	Eksterne metrike	13
6.2.1	Adjusted Rand Index (ARI)	13
6.2.2	Normalized Mutual Information (NMI)	13
6.3	Dodatni pokazatelji	14
7	Vizuelizacija podataka i rezultata	14
7.1	Vizuelizacija originalnih oznaka u 2D prostoru	14
7.2	Vizuelizacija klastera najboljih modela	15
7.3	Poređenje metrika između modela	20
7.4	Analiza parametara DBSCAN algoritma	21
7.5	Analiza izbora broja klastera	22
8	Rezultati i analiza	23
8.1	Najbolji rezultati po algoritmima	23
8.2	Poređenje algoritama	24
8.3	Uticaj reprezentacije podataka	24
8.4	Uticaj parametara	24
8.5	Poređenje metrika	25
8.6	Efikasnost algoritama	25
8.7	Poređenje interpretabilnosti klastera	25
9	Zaključak	26

1 Uvod

U oblasti istraživanja podataka (eng. *data mining*), klasterovanje predstavlja jednu od osnovnih tehnika nenadgledanog učenja čiji je cilj grupisanje objekata u skupove (klasteri) na osnovu njihove međusobne sličnosti. Za razliku od nadgledanog učenja, kod klasterovanja ne postoje unapred definisane oznake, već se struktura podataka otkriva isključivo na osnovu njihovih karakteristika.

Primena klasterovanja je veoma široka i obuhvata različite domene kao što su obrada teksta, analiza korisničkog ponašanja, bioinformatika i sistemi za preporuku. Poseban izazov predstavljaju visoko-dimenzionalni i retki (eng. *sparse*) podaci, kakvi se često javljaju u obradi tekstualnih informacija.

Retki podaci su oni kod kojih je većina vrednosti u matrici karakteristika jednaka nuli. Na primer, u tekstualnim reprezentacijama kao što je *bag-of-words*, svaki dokument sadrži samo mali broj reči iz ukupnog rečnika, pa većina atributa za dati dokument ima vrednost nula. Zbog toga se ovakvi podaci obično čuvaju u posebnim retkim formatima, koji pamte samo nenulte vrednosti i time značajno smanjuju potrošnju memorije.

U ovom radu analizirano je klasterovanje nad IMDB skupom podataka koji sadrži informacije o filmovima, pri čemu su atributi izvedeni iz tekstualnih opisa. Zbog tekstualne prirode atributa, podaci su visoko-dimenzionalni i retki, što dodatno komplikuje proces klasterovanja i zahteva primenu odgovarajućih tehnika preprocesiranja.

Cilj rada je poređenje performansi različitih algoritama klasterovanja nad istim skupom podataka, kao i analiza uticaja reprezentacije podataka i izbora parametara na kvalitet dobijenih klastera. Poseban fokus stavljen je na upoređivanje rezultata dobijenih nad originalnim (retkim) podacima i nad redukovanim reprezentacijama dobijenim primenom metode redukcije dimenzionalnosti.

U okviru rada primenjeni su različiti algoritmi klasterovanja, uključujući MiniBatchK-Means, hijerarhijsko klasterovanje, Gaussian Mixture Model, Birch i DBSCAN. Dobijeni rezultati evaluirani su korišćenjem više metrika, kako internih, tako i eksternih, a prikazani su i odgovarajući grafički prikazi radi lakše interpretacije.

2 Opis skupa podataka

U ovom radu korišćen je IMDB skup podataka koji sadrži informacije o filmovima, pri čemu su atributi izvedeni iz tekstualnih opisa. Skup podataka je preuzet sa platforme OpenML i predstavlja tipičan primer visoko-dimenzionalnih i retkih podataka koji se često javljaju u obradi prirodnog jezika.

2.1 Poreklo i osnovne karakteristike

IMDB skup podataka obuhvata veliki broj filmova, pri čemu je svaki film predstavljen skupom numeričkih atributa koji potiču iz tekstualnih karakteristika, kao što su opis radnje, ključne reči ili drugi metapodaci. Ovi atributi su najčešće generisani korišćenjem tehnika kao što su *bag-of-words* ili slični pristupi za reprezentaciju teksta.

Podaci su organizovani u matricu karakteristika X i vektor oznaka y . Skup podataka sadrži ukupno 120 919 instanci (filmova) i 1001 atribut. Svaka instanca predstavlja jedan film, dok atributi odgovaraju numeričkim karakteristikama izvedenim iz tekstualnih opisa.

Matrica X je veoma visoke dimenzionalnosti, pri čemu većina vrednosti iznosi nula, što znači da je reč o retkoj reprezentaciji. Ovakva struktura podataka značajno utiče na izbor algoritama i metoda obrade, jer standardne metrike rastojanja mogu postati manje informativne u visoko-dimenzionalnom prostoru.

2.2 Struktura atributa

Atributi u skupu podataka predstavljaju numeričke vrednosti koje odgovaraju učestalosti pojavljivanja određenih termina u tekstualnom opisu filma (*bag-of-words* reprezentacija). Svaki red u matrici X odgovara jednom filmu, dok svaka kolona predstavlja određeni termin.

Drugim rečima, vrednost X_{ij} predstavlja broj pojavljivanja termina j u dokumentu i , a ne samo informaciju o prisustvu termina. Ovakva reprezentacija omogućava algoritmima da uzmu u obzir značaj pojedinih termina u dokumentu.

Zbog prirode tekstualnih podataka, većina atributa ima vrednost nula za dati primer, što znači da se veliki deo prostora karakteristika ne koristi za svaki pojedinačni objekat. Ova osobina dovodi do visoke retkosti podataka, što može negativno uticati na performanse određenih algoritama klasterovanja, posebno onih koji se oslanjaju na rastojanja u originalnom prostoru.

2.3 Ciljna promenljiva i njena uloga u evaluaciji

Iako je klasterovanje nenadgledan proces, u ovom skupu podataka dostupna je i ciljna promenljiva y , koja predstavlja binarnu klasifikaciju filmova. Konkretno, vrednost $y = 1$ označava da film pripada kategoriji drama, dok $y = 0$ označava da film ne pripada toj kategoriji.

Ove oznake nisu korišćene tokom samog procesa klasterovanja, već isključivo za evaluaciju dobijenih rezultata. Na osnovu njih moguće je izračunati eksterne metrike kao što su

Adjusted Rand Index (ARI) i Normalized Mutual Information (NMI), koje mere stepen slaganja između dobijenih klastera i stvarnih oznaka.

Prisustvo ciljne promenljive omogućava objektivniju procenu kvaliteta klasterovanja i pruža dodatni uvid u to koliko dobro algoritmi uspevaju da otkriju latentnu strukturu podataka.

3 Preprocesiranje podataka

S obzirom na to da IMDB skup podataka sadrži visoko-dimenzionalne i retke podatke izvedene iz tekstualnih karakteristika, preprocesiranje predstavlja ključan korak u pripremi podataka za primenu algoritama klasterovanja. U ovom radu izvršeno je nekoliko faza obrade podataka sa ciljem poboljšanja kvaliteta reprezentacije i efikasnosti algoritama.

3.1 Učitavanje i početna obrada

Podaci su učitani iz unapred pripremljenih fajlova u retkom formatu. Matrica karakteristika X učitana je kao retka matrica, dok je vektor oznaka y učitao kao niz vrednosti. Ovakav format omogućava efikasno čuvanje i obradu podataka sa velikim brojem nula.

3.2 Provera i uklanjanje praznih atributa

U okviru preprocesiranja predviđena je zaštitna mera za uklanjanje atributa koji ne sadrže nijednu nenultu vrednost, odnosno kolona koje su u potpunosti prazne. Takvi atributi ne doprinose razlikovanju između instanci i njihovo prisustvo bi samo povećalo dimenzionalnost podataka.

Međutim, dodatna inspekcija retke matrice pokazala je da u konkretnom IMDB skupu podataka nije bilo takvih kolona. Zbog toga ova faza u konkretnom slučaju nije promenila broj atributa, već služi kao mera predostrožnosti radnog toka u slučaju da se nad drugim skupovima ili verzijama podataka pojave potpuno prazne karakteristike.

3.3 Skaliranje podataka

Nakon uklanjanja praznih atributa, izvršeno je skaliranje podataka korišćenjem metode *MaxAbsScaler*. Ova metoda skalira svaku karakteristiku u opseg $[-1, 1]$, pri čemu se očuva retka struktura podataka.

Za razliku od standardnih metoda skaliranja koje mogu uništiti retkost, *MaxAbsScaler* je

posebno pogodan za rad sa retkim matricama, jer ne uvodi nove nenulte vrednosti.

3.4 Stratifikovano uzorkovanje

Zbog velike veličine skupa podataka, izvršeno je uzorkovanje kako bi se smanjila računarska složenost algoritama. Korišćen je stratifikovani pristup uzorkovanju, pri čemu se zadržava proporcionalna zastupljenost klasa definisanih promenljivom y .

Od originalnih 120 919 instanci izdvojen je stratifikovani uzorak od 15 000 instanci. Ovaj uzorak se u nastavku rada označava kao X_{sample} i predstavlja osnovu za sve eksperimente klasterovanja. Nad njim su zatim formirane i SVD reprezentacije korišćene u eksperimentima i vizuelizaciji.

Na ovaj način smanjena je računarska zahtevnost eksperimenata, dok je zadržana približna raspodela stvarnih oznaka iz originalnog skupa podataka, što je posebno važno za evaluaciju rezultata.

3.5 Redukcija dimenzionalnosti primenom SVD metode

Jedan od ključnih koraka u preprocesiranju bila je redukcija dimenzionalnosti primenom metode *Truncated Singular Value Decomposition (Truncated SVD)*. Ova metoda omogućava projekciju podataka u prostor niže dimenzionalnosti uz očuvanje što veće količine informacija.

Redukcija dimenzionalnosti je izvršena na uzorkovanom i skaliranom skupu podataka X_{sample} , koji sadrži 15 000 instanci. Za potrebe eksperimenata generisane su guste SVD reprezentacije sa 100, 50 i 20 komponenti. Pored toga, generisane su i SVD reprezentacije sa 2 i 3 komponente, ali one nisu korišćene za treniranje glavnih modela, već isključivo za 2D i 3D vizuelizaciju podataka i dobijenih klastera.

Primena SVD metode ima više prednosti:

- smanjuje dimenzionalnost podataka i time ubrzava algoritme,
- može da ublaži uticaj šuma i retkih karakteristika,
- omogućava lakšu vizuelizaciju podataka u 2D i 3D prostoru.

Na kraju ovog procesa dobijene su sledeće reprezentacije korišćene u daljem radu:

- **full_sparse** – uzorkovani i skalirani podaci X_{sample} u originalnom retkom prostoru atributa,

- **svd_100, svd_50, svd_20** – redukovane guste reprezentacije korišćene u eksperimentima,
- **svd_2, svd_3** – reprezentacije korišćene za vizuelizaciju.

4 Metodologija

U ovom radu primenjen je skup različitih algoritama klasterovanja sa ciljem analize njihovih performansi nad visoko-dimenzionalnim i retkim podacima. Poseban fokus stavljen je na poređenje algoritama različitih tipova, kao i na uticaj reprezentacije podataka na kvalitet dobijenih klastera.

4.1 Pristup klasterovanju

Klasterovanje predstavlja nenadgledani proces učenja čiji je cilj grupisanje objekata tako da objekti unutar istog klastera budu međusobno slični, dok objekti iz različitih klastera budu što različitiji. Sličnost između objekata u ovom radu meri se korišćenjem odgovarajućih metrika rastojanja u prostoru karakteristika.

S obzirom na prirodu podataka, primenjeni su algoritmi koji pripadaju različitim kategorijama klasterovanja, uključujući klasterovanje bazirano na centroidima, klasterovanje bazirano na gustini, hijerarhijske i probabilističke metode. Ovakav pristup omogućava sveobuhvatnu analizu i poređenje različitih strategija klasterovanja.

U ovom radu korišćene su metrike i postupci koji odgovaraju konkretnom algoritmu i reprezentaciji podataka. Za redukovane SVD reprezentacije korišćeni su gusti vektori, nad kojima su primenjeni svi algoritmi.

Kod reprezentacije **full_sparse**, odnosno nad uzorkovanim podacima u originalnom retkom prostoru, primenjivani su samo algoritmi koji podržavaju redak ulaz: MiniBatchKMeans i DBSCAN. Za DBSCAN nad retkom reprezentacijom korišćena je kosinusna metrika, jer je pogodna za tekstualne retke podatke. MiniBatchKMeans je nad retkom reprezentacijom korišćen sa svojim podrazumevanim načinom računanja klastera.

4.2 Reprezentacije podataka

Eksperimenti su sprovedeni nad različitim reprezentacijama podataka, kako bi se ispitao uticaj dimenzionalnosti i retkosti na performanse algoritama.

Korišćene su sledeće reprezentacije:

- **full_sparse** – uzorkovani i skalirani skup X_{sample} u originalnom retkom prostoru atributa. Ova reprezentacija zadržava originalne karakteristike nakon preprocesiranja, ali ostaje visoko-dimenzionalna i retka.
- **svd_100**, **svd_50**, **svd_20** – guste reprezentacije dobijene primenom Truncated SVD metode nad X_{sample} , korišćene za treniranje i poređenje algoritama.
- **svd_2**, **svd_3** – projekcije korišćene samo za vizuelizaciju podataka i klastera.

Upoređivanjem rezultata nad ovim reprezentacijama moguće je analizirati kompromis između očuvanja informacija i efikasnosti algoritama.

4.3 Izabrani algoritmi klasterovanja

U radu je korišćeno pet različitih algoritama klasterovanja, koji pokrivaju različite pristupe problemu:

4.3.1 MiniBatchKMeans

MiniBatchKMeans predstavlja varijantu KMeans algoritma koja koristi male nasumične poduzorke (mini-batch) podataka radi ubrzanja procesa učenja. Ovaj algoritam je posebno pogodan za velike skupove podataka jer značajno smanjuje vreme izvršavanja u odnosu na standardni KMeans.

Izabran je kao osnovni (baseline) algoritam zbog svoje jednostavnosti, efikasnosti i široke primene u praksi.

4.3.2 Agglomerative Clustering

Agglomerative klasterovanje predstavlja hijerarhijski pristup u kome svaki objekat inicijalno formira svoj klaster, nakon čega se klasteri iterativno spajaju na osnovu kriterijuma sličnosti.

Prednost ovog pristupa je u tome što ne zahteva pretpostavke o obliku klastera i omogućava fleksibilnije modelovanje strukture podataka.

4.3.3 Gaussian Mixture Model (GMM)

Gaussian Mixture Model predstavlja probabilistički pristup klasterovanju u kome se pretpostavlja da su podaci generisani iz mešavine više normalnih raspodela. Za razliku od

KMeans algoritma, GMM može da modeluje pripadnost instance komponentama preko verovatnoća.

U implementaciji eksperimenata, za evaluaciju i poređenje korišćena je konkretna oznaka klastera dobijena funkcijom `fit_predict`, odnosno svaka instanca je pridružena najverovatnijoj komponenti. Na taj način su GMM rezultati poredivi sa ostalim algoritmima preko istih metrika evaluacije.

4.3.4 Birch

Birch (Balanced Iterative Reducing and Clustering using Hierarchies) je algoritam dizajniran za efikasno klasterovanje velikih skupova podataka. On koristi kompaktnu reprezentaciju podataka kroz tzv. CF (Clustering Feature) stabla, čime omogućava skalabilnost i brzinu.

Birch predstavlja kompromis između brzine i kvaliteta klasterovanja i često se koristi u praksi za rad sa velikim skupovima podataka.

4.3.5 DBSCAN

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) je algoritam koji grupiše objekte na osnovu gustine. Klasteri se formiraju kao oblasti visoke gustine, dok se objekti koji ne pripadaju nijednom klasteru označavaju kao šum (eng. noise).

Prednost DBSCAN algoritma je u tome što ne zahteva unapred zadat broj klastera i može detektovati klasterne proizvoljnog oblika. Međutim, njegova performansa u velikoj meri zavisi od izbora parametara, kao što su ε (epsilon) i minimalan broj suseda.

Kombinovanjem ovih algoritama omogućeno je poređenje različitih pristupa klasterovanju i analiza njihovog ponašanja u zavisnosti od karakteristika podataka.

5 Eksperimentalno podešavanje

U ovom radu sproveden je niz eksperimenata sa ciljem analize performansi različitih algoritama klasterovanja nad različitim reprezentacijama podataka. Eksperimenti su organizovani sistematično, tako da obuhvate više kombinacija algoritama i parametara, čime je omogućeno detaljno poređenje rezultata.

5.1 Korišćene reprezentacije

Eksperimenti su sprovedeni nad sledećim reprezentacijama podataka:

- **full_sparse** – uzorkovani i skalirani skup X_{sample} od 15 000 instanci u originalnom retkom prostoru karakteristika,
- **svd_100** – SVD reprezentacija sa 100 komponenti,
- **svd_50** – SVD reprezentacija sa 50 komponenti,
- **svd_20** – SVD reprezentacija sa 20 komponenti.

Reprezentacije **svd_2** i **svd_3** nisu korišćene za glavne eksperimente klasterovanja, već za vizuelizaciju podataka i rezultujućih klaster oznaka u 2D i 3D prostoru.

5.2 Parametri algoritama

Za svaki algoritam ispitane su različite vrednosti ključnih parametara kako bi se analizirala njihova osetljivost i uticaj na kvalitet klasterovanja.

Tabela 1: Pregled korišćenih parametara algoritama

Algoritam	Reprezentacije	Parametri
MiniBatchKMeans	full_sparse, svd_100, svd_50, svd_20	n_clusters $\in \{2, 3, 5, 7\}$
Agglomerative	svd_100, svd_50, svd_20	n_clusters $\in \{2, 3, 5, 7\}$
GMM	svd_100, svd_50, svd_20	n_components $\in \{2, 3, 5, 7\}$
Birch	svd_100, svd_50, svd_20	n_clusters $\in \{2, 3, 5, 7\}$
DBSCAN	svd_100, svd_50, svd_20	$\varepsilon \in \{0.3, 0.5, 0.7, 1.0, 1.5\}$, min_samples $\in \{5, 10\}$
DBSCAN	full_sparse	$\varepsilon \in \{0.3, 0.5, 0.7, 1.0\}$, min_samples $\in \{5, 10\}$, kosinusna metrika

Za DBSCAN algoritam nad reprezentacijom **full_sparse** korišćena je kosinusna metrika rastojanja, što je u skladu sa praksom u obradi tekstualnih retnih podataka.

5.3 Organizacija eksperimenata

Eksperimenti su organizovani kao kombinacija:

- različitih reprezentacija podataka,
- različitih algoritama klasterovanja,
- različitih vrednosti parametara.

Za svaku kombinaciju izvršeno je treniranje modela i generisanje odgovarajućih klaster oznaka. Rezultati svakog eksperimenta beleženi su u vidu:

- oznaka klastera za svaki objekat,
- konfiguracije parametara,
- vrednosti evaluacionih metrika,
- informacije o tome da li je naučeni model uspešno sačuvan.

Modeli su čuvani tamo gde je to bilo moguće. Nezavisno od toga da li je kompletan objekat modela uspešno serijalizovan, za svaki eksperiment su sačuvane klaster oznake, konfiguracija i metrike, što omogućava naknadnu analizu rezultata.

Za potrebe poređenja algoritama u tabelama i grafikonima korišćen je kriterijum maksimalne vrednosti Adjusted Rand Index (ARI) metrike. Važno je razlikovati dva nivoa izbora:

- najbolji model po algoritmu, koji se koristi za poređenje algoritama u glavnoj tabeli,
- najbolji model za svaku kombinaciju algoritma i reprezentacije, koji se koristi u dodatnim analizama, uključujući analizu klastera preko najkarakterističnijih reči.

Kod Birch algoritma čuvanje kompletnog objekta modela u ovom eksperimentalnom okruženju nije uspelo za sve konfiguracije, pa se za te eksperimente oslanjamo na sačuvane oznake klastera, konfiguracije i metrike.

5.4 Čuvanje rezultata i reproduktivnost

Svi rezultati eksperimenata organizovani su u strukturi direktorijuma, tako da se kompletan postupak može ponoviti u lokalnom okruženju. Korišćena je sledeća organizacija:

- `data/raw` – početni podaci preuzeti sa OpenML platforme,
- `data/processed` – preprocesirani podaci, uključujući `X_sample.npz`, `y_sample.npy` i SVD reprezentacije,

- `models/preprocessing` – sačuvani objekti korišćeni u preprocesiranju, kao što su scaler i SVD modeli,
- `models/clustering` – sačuvani modeli klasterovanja, kada je serijalizacija uspešna,
- `results/cluster_reports` – oznake klastera za pojedinačne eksperimente, sačuvane kao `.numpy` nizovi,
- `results/configs` – konfiguracije eksperimenata u JSON formatu,
- `results/metrics` – evaluacione metrike u CSV formatu,
- `results/plots` – generisani grafički prikazi,
- `results/cluster_analysis` – rezultati analize klastera preko najkarakterističnijih reči.

Za svaki eksperiment beleži se i informacija `model_saved`, kao i eventualna greška pri čuvanju modela. Na taj način, čak i u slučajevima kada kompletan objekat modela nije uspešno sačuvan, ostaju dostupne klaster oznake, konfiguracija i metrike, što omogućava naknadnu analizu i poređenje rezultata.

6 Metrike evaluacije

Za procenu kvaliteta dobijenih klastera korišćen je skup različitih metrika koje se mogu podeliti na interne i eksterne metrike. Interne metrike ocenjuju kvalitet klastera na osnovu same strukture podataka, dok eksterne metrike porede dobijene klastere sa stvarnim oznakama.

Treba napomenuti da sve interne metrike nisu uvek dostupne za svaku reprezentaciju. Na primer, Davies–Bouldin i Calinski–Harabasz indeks računati su samo kada je ulazna reprezentacija gusta, dok kod retke reprezentacije mogu ostati nedefinisani. Zbog toga se u poređenju posebna pažnja posvećuje metrikama ARI i NMI, koje su dostupne za sve eksperimente i koriste stvarne oznake samo u fazi evaluacije.

Pored toga, analizirani su i dodatni pokazatelji kao što su vreme izvršavanja i broj detektovanih klastera.

6.1 Interne metrike

Interne metrike mere kvalitet klasterovanja bez korišćenja stvarnih oznaka, oslanjajući se isključivo na geometrijsku strukturu podataka.

6.1.1 Silhouette koeficijent

Silhouette koeficijent meri koliko je svaki objekat dobro uklopljen u svoj klaster u odnosu na najbliži susedni klaster. Vrednost ove metrike kreće se u opsegu $[-1, 1]$, gde veće vrednosti ukazuju na bolje definisane klastere.

Visoka vrednost silhouette koeficijenta znači da su objekti unutar istog klastera međusobno slični, dok su dobro razdvojeni od objekata iz drugih klastera.

6.1.2 Davies–Bouldin indeks

Davies–Bouldin indeks meri odnos između unutrašnje raspršenosti klastera i međusobne udaljenosti klastera. Niže vrednosti ovog indeksa ukazuju na bolje klasterovanje.

Ova metrika favorizuje rešenja u kojima su klasteri kompaktni i međusobno dobro razdvojeni.

6.1.3 Calinski–Harabasz indeks

Calinski–Harabasz indeks predstavlja odnos između disperzije između klastera i disperzije unutar klastera. Veće vrednosti ukazuju na bolje klasterovanje.

Ova metrika nagrađuje rešenja u kojima su klasteri jasno razdvojeni i kompaktni.

6.2 Eksterne metrike

Eksterne metrike koriste stvarne oznake podataka (promenljivu y) kako bi ocenile koliko se dobijeni klasteri poklapaju sa poznatom strukturom podataka.

6.2.1 Adjusted Rand Index (ARI)

Adjusted Rand Index meri sličnost između dobijenog klasterovanja i stvarnih oznaka, uz korekciju za slučajno poklapanje. Vrednosti se kreću od -1 do 1 , gde vrednosti bliže 1 ukazuju na bolje slaganje.

ARI je posebno koristan jer uzima u obzir sve parove objekata i proverava da li su pravilno grupisani zajedno ili razdvojeni.

6.2.2 Normalized Mutual Information (NMI)

Normalized Mutual Information meri količinu zajedničke informacije između dobijenih klastera i stvarnih oznaka. Vrednosti se kreću u opsegu $[0, 1]$, gde veće vrednosti označavaju

bolje poklapanje.

Ova metrika je zasnovana na teoriji informacija i posebno je pogodna za poređenje različitih klasterovanja.

6.3 Dodatni pokazatelji

Pored standardnih metrika, analizirani su i dodatni pokazatelji koji daju dodatni uvid u ponašanje algoritama:

- **Vreme izvršavanja** – meri efikasnost algoritma i njegovu pogodnost za rad sa većim skupovima podataka.
- **Broj pronađenih klastera** – omogućava analizu stabilnosti algoritma u odnosu na zadate parametre.
- **Broj noise tačaka** – pokazatelj koji se koristi kod DBSCAN algoritma, jer ovaj algoritam može označiti objekte koji ne pripadaju nijednom klasteru kao šum.

Kombinovanjem različitih metrika moguće je dobiti potpuniju sliku o kvalitetu klasterovanja, s obzirom na to da svaka metrika meri različite aspekte strukture podataka.


7 Vizuelizacija podataka i rezultata

Vizuelizacija podataka i rezultata predstavlja važan deo analize klasterovanja, jer omogućava intuitivno razumevanje strukture podataka i ponašanja algoritama. U ovom radu generisan je veći broj grafičkih prikaza, uključujući prikaze originalnih oznaka, klastera dobijenih različitim algoritmima, poređenje metrika i analizu uticaja parametara.

Zbog preglednosti i ograničenja prostora u dokumentu, u radu su prikazani pre svega modeli koji su za dati algoritam postigli najbolju vrednost ARI metrike. Na taj način izbor prikazanih grafika nije zasnovan na subjektivnom izboru, već na istom kriterijumu koji se koristi i u numeričkoj evaluaciji rezultata. Svi ostali generisani grafici dostupni su u okviru projektnog repozitorijuma.

7.1 Vizuelizacija originalnih oznaka u 2D prostoru

U cilju boljeg razumevanja strukture podataka, korišćena je redukcija dimenzionalnosti na 2 komponente primenom SVD metode. Ova projekcija omogućava vizuelni uvid u raspodelu podataka i potencijalno postojanje klastera.




Slika 1: 2D prikaz podataka u SVD prostoru (2 komponente) obojen prema stvarnim oznakama (drama / ne-drama)

7.2 Vizuelizacija klastera najboljih modela


Za svaki algoritam prikazan je model koji je postigao najbolju ARI vrednost među ispitivanim reprezentacijama i parametrima. Klaster oznake su dobijene iz odgovarajuće reprezentacije nad kojom je model treniran, dok su sve slike prikazane u istom 2D SVD prostoru radi lakšeg vizuelnog poređenja. Zbog toga ove slike treba posmatrati kao projekciju rezultata, a ne kao potpun prikaz prostora u kome je svaki model treniran.

Pored vizuelnog prikaza, za svaki prikazani model analizirane su i najkarakterističnije reči po klasterima. One su izračunate u originalnom prostoru atributa, nad matricom X_{sample} , čak i kada je sam model treniran nad SVD reprezentacijom. Za svaku reč posmatrana je razlika između prosečne frekvencije u klasteru i globalne prosečne frekvencije nad celim uzorkom. Na taj način se svaki klaster može interpretirati preko reči koje su u njemu izraženije nego u proseku celog skupa.




Slika 2: Klasteri dobijeni MiniBatchKMeans algoritmom (najbolji model)

Za MiniBatchKMeans najbolji rezultat je dobijen nad reprezentacijom **svd_50**, sa 5 klastera i ARI vrednošću 0.0107. Iako se na 2D projekciji vidi značajno preklapanje između klastera, analiza najkarakterističnijih reči pokazuje da klasteri ipak hvataju određene tematske razlike. Klaster 2 je najveći i sadrži reči kao što su *documentary*, *show*, *interviews*, *film*, *footage*, *series*, pa se može povezati sa dokumentarnim i televizijskim sadržajem. Klaster 0 sadrži reči *love*, *falls*, *father*, *family*, *meets*, što ukazuje na ljubavne i porodične zaplete. Klaster 1 sadrži reči *police*, *murder*, *killed*, *dead*, *case*, pa odgovara kriminalističkim ili detektivskim sadržajima. Preostali klasteri obuhvataju opštije narativne motive kao što su *life*, *years*, *world*, *story* i likove opisane rečima *young*, *woman*, *man*, *girl*. Ipak, ovi tematski klasteri ne odgovaraju jasno podeli drama / ne-drama: u klasterima ostaje mešovita raspodela stvarnih oznaka, pa je slaganje sa ciljnom promenljivom nisko, što se odražava kroz malu ARI vrednost.




Slika 3: Klasteri dobijeni Agglomerative algoritmom (najbolji model)

Kod Agglomerative algoritma najbolji rezultat je dobijen nad reprezentacijom **svd_100**, takođe sa 5 klastera i ARI vrednošću 0.0103. Vizuelno, raspodela klastera podseća na MiniBatchKMeans, ali analiza reči pokazuje nešto drugačiju organizaciju tema. Najveći klaster 0 sadrži reči *war, tv, show, american, documentary, interviews, footage*, što ukazuje na dokumentarne, televizijske i ratne sadržaje. Klaster 1 obuhvata opštije dramske i porodične motive kroz reči *love, man, time, father, young, wife, woman*. Klaster 2 kombinuje reči *life, man, police, find, young, people*, pa sadrži mešavinu životnih i kriminalističkih motiva. Manji klasteri izdvajaju teme kao što su *story, true, based, life* i *love, lives, home, married, family*. I ovde se vidi da klasteri imaju određenu tekstualnu interpretaciju, ali se ne poklapaju jasno sa podelom drama / ne-drama.




Slika 4: Klasteri dobijeni GMM algoritmom (najbolji model)

Za GMM najbolji rezultat je dobijen nad reprezentacijom **svd_50**, sa 5 komponenti i ARI vrednošću 0.0055. U poređenju sa prethodnim algoritmima, GMM daje nešto drugačiju podelu prostora, ali najkarakterističnije reči ponovo pokazuju slične tematske grupe. Klaster 3 je najveći i sadrži reči *documentary, film, show, interviews, series, history, footage*, pa predstavlja dokumentarne i istorijske sadržaje. Klaster 2 sadrži reči *love, friends, life, lives, young, find*, što ukazuje na lične, društvene i ljubavne priče. Klaster 0 obuhvata reči *young, man, woman, wife, girl, father, son*, pa je više vezan za likove i porodične odnose. Klaster 4 dodatno izdvaja ljubavne motive preko reči *love, falls, young, woman, girl, meets*. Ipak, pošto su ove teme prisutne i u dramama i u filmovima koji nisu označeni kao drama, slaganje sa binarnom oznakom ostaje slabo.



Slika 5: Klasteri dobijeni Birch algoritmom (najbolji model)

Kod Birch algoritma najbolji rezultat je dobijen nad reprezentacijom **svd_20**, sa 3 klastera i ARI vrednošću 0.0100. Za razliku od prethodnih algoritama, Birch formira manji broj širih klastera. Najveći klaster 0 obuhvata najveći deo uzorka i sadrži reči *film*, *documentary*, *tv*, *world*, *interviews*, *footage*, *series*, *history*, što ukazuje na opšte filmske, dokumentarne i televizijske sadržaje. Klaster 1 je manji i sadrži reči *family*, *father*, *son*, *home*, *finds*, *life*, *wife*, pa se može povezati sa porodičnim i životnim temama. Klaster 2 sadrži reči *love*, *falls*, *meets*, *young*, *girl*, *woman*, *married*, što ukazuje na ljubavne zaplete. Ovakav rezultat je interpretabilan na tematskom nivou, ali je podela i dalje previše gruba da bi dobro pratila stvarnu oznaku drama / ne-drama.




Slika 6: Klasteri dobijeni DBSCAN algoritmom (najbolji model, uključujući noise tačke)

Za DBSCAN najbolji rezultat je dobijen nad reprezentacijom **svd_20**, sa ARI vrednošću 0.0041. Za razliku od ostalih algoritama, DBSCAN u ovom slučaju pronalazi jedan veliki klaster i značajan broj noise tačaka. Dominantni klaster 0 sadrži reči kao što su *di*, *_the*, *le*, *2000*, *featuring*, *del*, *el*, *il*, koje su manje interpretabilne i više liče na opšte ili jezički specifične tokene. Noise grupa sadrži reči *life*, *love*, *time*, *young*, *man*, *find*, *years*, *story*, što su veoma opšti narativni pojmovi. Zbog toga je DBSCAN rezultat slabije interpretabilan od rezultata algoritama koji formiraju više klastera. Ovaj prikaz potvrđuje da DBSCAN nije dobro prilagođen ovoj reprezentaciji podataka, jer umesto više smislenih gustinskih oblasti uglavnom razdvaja podatke na jednu veliku grupu i izdvojene tačke.

7.3 Poređenje metrika između modela


Radi poređenja performansi različitih algoritama, prikazan je grafikon koji ilustruje najbolje vrednosti ARI metrike za svaki algoritam i reprezentaciju podataka.



Slika 7: Poređenje najboljih ARI vrednosti po algoritmima i reprezentacijama

7.4 Analiza parametara DBSCAN algoritma

Za DBSCAN algoritam izvršena je analiza uticaja parametara ϵ i $min_samples$ korišćenjem heatmap prikaza.




Slika 8: Heatmap prikaz ARI vrednosti za različite parametre DBSCAN algoritma

Rezultati DBSCAN algoritma na SVD reprezentaciji sa 20 komponenti pokazuju da su ARI vrednosti veoma niske i uglavnom bliske nuli ili negativne. To ukazuje na slabo slaganje dobijenih klastera sa stvarnim oznakama. Najbolji rezultati se postižu za veće vrednosti parametra ε (oko 1.0), dok manje vrednosti dovode do negativnih ARI vrednosti, što znači da je klasterovanje lošije od slučajnog. Parametar *min_samples* nema značajan uticaj na performanse u ovom slučaju, jer su razlike između redova minimalne. Ovakvo ponašanje sugerise da DBSCAN nije dobro prilagođen strukturi ovog skupa podataka u datoj reprezentaciji.

7.5 Analiza izbora broja klastera

Za algoritme koji zahtevaju unapred zadat broj klastera analiziran je uticaj parametra k na kvalitet klasterovanja.



Slika 9: Zavisnost kvaliteta klasterovanja od broja klastera za MiniBatchKMeans

MiniBatchKMeans pokazuje stabilnije i bolje rezultate u odnosu na DBSCAN, sa najvišim ARI vrednostima za broj klastera između 3 i 5. Najbolje performanse postižu se na SVD reprezentaciji sa 50 komponenti, što ukazuje da srednja dimenzionalnost daje dobar balans između redukcije šuma i očuvanja informacija. Za manji ili veći broj klastera (npr. 2 ili 7), performanse opadaju, što sugerise da ti izbori ne odgovaraju stvarnoj strukturi podataka. Takođe, reprezentacija **full_sparse** pokazuje veću varijabilnost i lošije rezultate u nekim slučajevima, što dodatno potvrđuje značaj redukcije dimenzionalnosti.

8 Rezultati i analiza

U ovom poglavlju predstavljeni su rezultati primene različitih algoritama klasterovanja nad IMDB skupom podataka, kao i njihova analiza na osnovu korišćenih metrika. Poseban fokus stavljen je na Adjusted Rand Index (ARI), koji meri slaganje između dobijenih klastera i stvarnih oznaka, ali su razmatrane i druge metrike radi potpunije evaluacije.

Važno je naglasiti da veoma niske vrednosti ARI i NMI metrike ne znače nužno da su algoritmi neuspešni, već da ciljna promenljiva (drama / ne-drama) ne odražava prirodnu strukturu podataka. Klasteri koje algoritmi pronalaze mogu biti semantički smisleni, ali ne moraju odgovarati unapred definisanim klasama.

Zbog toga su rezultati analizirani iz dva ugla: prvo numerički, preko metrika evaluacije, a zatim interpretativno, preko najkarakterističnijih reči po klasterima.

8.1 Najbolji rezultati po algoritmima

U tabeli su prikazani najbolji rezultati po algoritmima, izabrani na osnovu maksimalne vrednosti ARI metrike.

Tabela 2: Najbolji rezultati po algoritmima

Algoritam	Reprezentacija	ARI	NMI	Vreme (s)
MiniBatchKMeans	SVD (50)	0.0107	0.0013	0.06
Agglomerative	SVD (100)	0.0103	0.0011	12.78
Birch	SVD (20)	0.0100	0.0008	1.50
GMM	SVD (50)	0.0055	0.0012	3.65
DBSCAN	SVD (20)	0.0041	0.0002	0.28

Na osnovu rezultata može se uočiti da MiniBatchKMeans i Agglomerative algoritmi postižu najbolje vrednosti ARI metrike, iako su apsolutne vrednosti relativno niske. Ovi rezultati ukazuju na ograničenu mogućnost algoritama da razdvoje podatke u skladu sa datim oznakama, što je u skladu sa prethodno diskutovanom prirodom skupa podataka.

MiniBatchKMeans se izdvaja kao najefikasniji algoritam, sa veoma kratkim vremenom izvršavanja, dok Agglomerative postiže sličan kvalitet uz značajno veću računarsku složenost. DBSCAN pokazuje najslabije rezultate u smislu ARI metrike, ali zadržava prednost u detekciji šuma.

8.2 Poređenje algoritama

Na osnovu dobijenih rezultata može se uočiti da različiti algoritmi pokazuju različito ponašanje u zavisnosti od reprezentacije podataka i izbora parametara.

MiniBatchKMeans algoritam se pokazao kao stabilan i pouzdan pristup, posebno nad redukovanim (SVD) reprezentacijama podataka. Njegove performanse su konzistentne kroz različite vrednosti parametra k , što ga čini dobrim izborom za početnu analizu.

Agglomerative i Birch algoritmi daju slične rezultate kao KMeans, ali su u nekim slučajevima osetljiviji na izbor broja klastera. Njihova prednost je u fleksibilnijem modelovanju strukture podataka, ali uz nešto veću računarsku složenost.

Gaussian Mixture Model pokazuje veću varijabilnost u rezultatima. Iako može modelovati složenije raspodele, njegova performansa zavisi od pretpostavki o distribuciji podataka, što u ovom slučaju ne dovodi uvek do poboljšanja rezultata.

DBSCAN algoritam se ponaša značajno drugačije u odnosu na ostale metode. Njegova najveća prednost je mogućnost detekcije šuma (noise), ali se pokazuje kao veoma osetljiv na izbor parametara.

8.3 Uticaj reprezentacije podataka

Jedan od najvažnijih zaključaka jeste da reprezentacija podataka značajno utiče na ponašanje algoritama. Redukovane SVD reprezentacije često daju stabilnije rezultate, jer smanjuju dimenzionalnost i omogućavaju algoritmima da rade nad gustim vektorima manjeg broja dimenzija.

Međutim, **full_sparse** reprezentaciju ne treba tumačiti kao ceo originalni skup podataka, već kao uzorkovani i skalirani skup X_{sample} u originalnom prostoru atributa. Ona zadržava originalne retke karakteristike nakon preprocesiranja, ali i dalje nosi probleme visoke dimenzionalnosti i retkosti podataka.

U rezultatima se vidi da su najbolje ARI vrednosti za većinu algoritama dobijene nad SVD reprezentacijama. To ukazuje da redukcija dimenzionalnosti pomaže u stabilizaciji klasterovanja, ali apsolutne vrednosti ARI ostaju niske, što znači da dobijeni klasteri ne prate dobro binarnu oznaku drama / ne-drama.

8.4 Uticaj parametara

Analiza uticaja parametara pokazuje da kvalitet klasterovanja značajno zavisi od njihovog izbora.

Kod algoritama koji zahtevaju unapred zadat broj klastera (k), primećuje se da ne postoji jedinstvena optimalna vrednost koja daje najbolje rezultate u svim slučajevima. Optimalan izbor zavisi od reprezentacije podataka i same metrike koja se posmatra.

Kod DBSCAN algoritma, parametar ε ima ključnu ulogu u formiranju klastera. Male promene u njegovoj vrednosti mogu dovesti do velikih promena u broju klastera i količini detektovanog šuma. Heatmap analiza jasno pokazuje ovu osetljivost, kao i postojanje ograničenog opsega parametara u kome algoritam daje smislene rezultate.

8.5 Poređenje metrika

Poređenjem različitih metrika može se uočiti da interne i eksterne metrike ne moraju uvek davati iste zaključke.

Dok interne metrike (kao što su silhouette i Davies–Bouldin indeks) ocenjuju kompaktnost i razdvojenost klastera, eksterne metrike (ARI i NMI) mere slaganje sa stvarnim oznakama. U ovom radu primećeno je da neke interne metrike mogu davati relativno povoljnije vrednosti od eksternih metrika, ali to ne znači nužno da su klasteri semantički idealni. To samo pokazuje da geometrijska kompaktnost klastera i slaganje sa oznakom drama / ne-drama mere različite aspekte rezultata.

Zbog toga je neophodno koristiti više metrika prilikom evaluacije, kako bi se dobila potpunija slika o kvalitetu klasterovanja.

8.6 Efikasnost algoritama

Pored kvaliteta klasterovanja, analizirano je i vreme izvršavanja algoritama.

MiniBatchKMeans i Birch algoritmi se izdvajaju kao najefikasniji, što ih čini pogodnim za rad sa većim skupovima podataka. Agglomerative i GMM algoritmi su sporiji, dok DBSCAN može biti efikasan, ali njegova složenost zavisi od izbora parametara i strukture podataka.

Na osnovu svega navedenog, može se zaključiti da ne postoji jedinstveno najbolji algoritam za sve slučajeve, već izbor algoritma i parametara zavisi od konkretnih karakteristika podataka i ciljeva analize.

8.7 Poređenje interpretabilnosti klastera

Analiza najkarakterističnijih reči, prikazana uz scatter grafike u prethodnom poglavlju, pokazuje da klasteri nisu potpuno slučajni, iako su ARI i NMI vrednosti veoma niske. Kod

više algoritama pojavljuju se slične tematske grupe: dokumentarni i televizijski sadržaji, ljubavni i porodični zapleti, kriminalistički motivi i opšti narativni opisi.

Interpretabilniji rezultati dobijeni su kod MiniBatchKMeans, Agglomerative, GMM i Birch algoritama, jer oni formiraju više klastera koji se mogu povezati sa različitim grupama reči. MiniBatchKMeans i Agglomerative daju slične podele, dok Birch formira manji broj širih klastera. GMM takođe izdvaja slične teme, ali uz niže slaganje sa stvarnim oznakama. DBSCAN je najmanje interpretabilan u ovom eksperimentu, jer uglavnom formira jedan dominantan klaster i veliki broj noise tačaka.

Važno je naglasiti da se ove tematske grupe ne poklapaju jasno sa binarnom oznakom drama / ne-drama. Skoro svi analizirani klasteri imaju dominantnu stvarnu oznaku 0, a čistoća klastera je uglavnom umerenog nivoa. To znači da algoritmi uspevaju da pronađu određene tematske obrasce u tekstualnim atributima, ali ti obrasci ne odgovaraju direktno ciljnoj promenljivoj korišćenoj za eksternu evaluaciju.

9 Zaključak

U ovom radu analizirana je primena različitih algoritama klasterovanja nad IMDB skupom podataka koji karakterišu visoka dimenzionalnost i retkost (eng. sparsity). Korišćenjem više algoritama, različitih reprezentacija podataka i širokog spektra parametara, omogućeno je detaljno poređenje njihovih performansi.

Rezultati jasno ukazuju na to da reprezentacija podataka ima ključnu ulogu u kvalitetu klasterovanja, često važniju od samog izbora algoritma. Redukcija dimenzionalnosti primenom SVD metode u većini slučajeva dovodi do stabilnijih rezultata, jer smanjuje dimenzionalnost prostora, ublažava uticaj retkih karakteristika i olakšava algoritmima pronalaženje strukture u podacima.

Među analiziranim algoritmima, MiniBatchKMeans se izdvojio kao stabilan i efikasan pristup, dok su Agglomerative i Birch algoritmi pokazali slične performanse uz nešto veću računarsku složenost. Gaussian Mixture Model omogućava fleksibilnije modelovanje, ali nije uvek davao bolje rezultate u odnosu na jednostavnije metode. DBSCAN algoritam se pokazao korisnim za detekciju šuma i klastera proizvoljnog oblika, ali uz izraženu osetljivost na izbor parametara.

Takođe je uočeno da različite metrike evaluacije mogu davati različite zaključke, što ukazuje na potrebu za kombinovanjem više metrika prilikom procene kvaliteta klasterovanja.

Na osnovu sprovedene analize može se zaključiti da ne postoji univerzalno najbolji algoritam za sve slučajeve, već izbor metode zavisi od karakteristika podataka i ciljeva analize. U praksi, kombinacija redukcije dimenzionalnosti i jednostavnih, skalabilnih algoritama

predstavlja dobar početni pristup.

Analiza klastera preko najkarakterističnijih reči pokazala je da dobijeni klasteri ipak imaju određenu tematsku interpretaciju. Kod više algoritama izdvajaju se grupe povezane sa dokumentarnim sadržajima, ljubavnim i porodičnim zapletima, kriminalističkim motivima i opštim narativnim opisima. Ipak, te tematske grupe se ne poklapaju jasno sa binarnom oznakom drama / ne-drama, što objašnjava zašto su ARI i NMI vrednosti ostale niske.

Kao mogući pravci budućeg rada izdvajaju se:

- primena naprednijih tehnika redukcije dimenzionalnosti,
- ispitivanje dodatnih metrika sličnosti za tekstualne podatke,
- primena dubokih modela za reprezentaciju teksta,
- analiza drugih skupova podataka radi generalizacije zaključaka.

Literatura

- [1] Scikit-learn Documentation.
<https://scikit-learn.org/>
- [2] OpenML dataset: IMDB (drama classification).
<https://www.openml.org/search?type=data&id=273>
- [3] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, Vipin Kumar.
Introduction to Data Mining. Pearson, 2nd edition, 2018.
- [4] Xindong Wu et al.
Top 10 algorithms in data mining. *Knowledge and Information Systems*, 14(1), 2008.